

Техническое задание

AI-чат-бот для менеджеров

1. Общая информация

Наименование проекта:

Разработка и внедрение внутреннего AI-чат-бота для поддержки менеджеров компании Highland Gold.

Назначение проекта:

Проект направлен на создание интеллектуальной системы поиска и предоставления информации для менеджеров компании. Основная функция чат-бота заключается в обеспечении быстрого доступа к актуальным внутренним регламентам, инструкциям, кейсам и шаблонам коммуникаций с целью снижения ошибок при работе с персоналом, сокращения времени на поиск документов и стандартизации управленческих решений.

Форматы использования:

Чат-бот должен быть доступен в нескольких каналах коммуникации: через существующий корпоративный мессенджер-бот «Капитан Хайленд», внутренний корпоративный портал Highland Gold Online, мобильное приложение портала, а также иметь возможность взаимодействия с другими внутренними сервисами (см. ниже).

Для этапа MVP разработка нового самостоятельного пользовательского интерфейса не выполняется. Функциональность чат-бота встраивается в действующие каналы («Капитан Хайленд», внутренний портал Highland Gold Online, мобильное приложение). Административные операции выполняются через **встроенную страницу существующего корпоративного портала**, используемую исключительно для загрузки материалов и назначения метаданных; создание отдельного административного приложения не предусмотрено.

Требования к размещению:

Все компоненты системы должны быть развернуты в пределах корпоративной инфраструктуры (on-premise), без использования внешних API и облачных сервисов. Система должна быть спроектирована с учётом дальнейшего масштабирования на всю организацию, включая возможность поддержки до 1000 пользователей одновременно.

2. Цели и задачи проекта

2.1. Цель разработки

Создать и внедрить ассистент для менеджеров компании Highland Gold, обеспечивающий быстрый, структурированный и достоверный доступ к актуальным внутренним регламентам, инструкциям, кейсам и шаблонам коммуникаций для снижения операционных рисков и повышения эффективности управленческих решений.

2.2. Бизнес-результаты

Система должна обеспечить сокращение времени поиска и интерпретации корпоративных документов, минимизацию ошибок, возникающих из-за использования устаревшей или неоднозначной информации, повышение стандартизации управленческих практик в типовых HR-ситуациях и улучшение качества внутренней коммуникации между руководителями и профильными подразделениями.

2.3. Задачи проекта

Определить единую точку входа для работы с базой знаний; обеспечить диалоговую обработку запросов на естественном языке с возможностью уточняющих вопросов; реализовать надёжный механизм извлечения релевантных фрагментов из источников и формирование кратких, структурированных и подтверждённых ответов; обеспечить актуальность и версионирование документов; реализовать разграничение доступа по ролям, типам менеджеров и организационной структуре.

2.4. Показатели успешности

Проект считается успешным при достижении следующих измеримых критериев: сокращение среднего времени до получения корректного ответа по типовым запросам не менее чем на 50% по сравнению с базовым процессом; доля ответов с положительной оценкой пользователей не ниже 80% по итогам пилота; доля ответов с подтверждающими ссылками/цитатами по запросам регуляторного характера не ниже 90%; снижение числа обращений к линейной поддержке по темам, покрытым базой знаний, не менее чем на 30% в течение первого квартала эксплуатации.

К 01.12.2025 система должна функционировать в продуктивной среде и использоваться целевой аудиторией. В рамках этапа MVP обеспечивается ведение журнала активности пользователей и качества ответов, включающего учёт количества диалогов и обращений по датам, доли запросов без ответа и распределения по тематикам, с возможностью последующей выгрузки данных в формате CSV для анализа профильными подразделениями.

2.5. Границы и допущения

Система покрывает управленческие и HR-сценарии, определённые в утверждённой номенклатуре категорий (адаптация, увольнение, обратная связь, премирование, трудные разговоры, KPI, онбординг) с возможностью расширения перечня. На этапе MVP допускается единая база знаний без детальной дифференциации по типам менеджеров при обязательной закладке соответствующих метаданных и политик доступа для последующего разукрупнения.

№	Вопрос	Ответ (кратко)	Требование к реализации (детализация)	Примечания (MVP → Final)
1	Сколько человек будет пользоваться ботом?	До 1000 пользователей	Архитектура бэкенда и векторного поиска проектируется с горизонтальным масштабированием; одновременная активность 20–30% без деградации; время отклика: поиск ≤ 3 с, генерация ≤ 8 с при стандартном контексте.	MVP: допускается пониженная одновременная активность; Final: подтверждение SLA по нагрузочному тесту.
2	Нужно ли разделение по видам менеджеров?	Да	Метаданные «тип менеджера» на уровне документа/фрагмента; фильтрация выдачи и контекста по роли/типу; интеграция с КИС/1С для проверки признака «руководитель».	MVP: единая БЗ с заложенной схемой метаданных; Final: включение политик доступа и фильтров.
3	База знаний статичная или обновляемая?	Обновляемая автоматически	Коннекторы к Confluence /Академии/М ИФ/файловым хранилищам; инкрементальная индексация без простоя; OCR для сканов; журнал	MVP: базовая синхронизация + ручной ребилд; Final: плановые задачи, мониторинг, оповещения.

Commented [AM01]: Нужно продумать как мы решим вопрос подгрузки информации, если в Confluence не у всех есть доступ к определённому разделу и доступ к системе. Возможно нужна промежуточная база знаний, в которую будет подгружаться вся возможная информация из разных источников и там аккумулироваться? Нужно это обсудить

			статусов и отчётность по индексации.	
4	Сколько документов на старте?	≥ 5 источников, ≥ 50 регламентов	Нормализация, разбиение на фрагменты (чанки с перекрытием), контроль версий и дат действия; исключение устаревших редакций из приоритетной выдачи.	MVP: индексирование стартового объёма; Final: расширение перечня источников и ретро-версий.
5	Какие форматы поддерживаются?	PDF, DOCX, XLSX, PPTX	PDF: текст+OCR; DOCX: заголовки/таблицы/сноски; XLSX: листы, заголовки, примечания; PPTX: слайды + speaker notes; единый интерфейс индексации.	MVP: поэтапное подключение форматов; Final: полная поддержка всех четырёх.
6	Какая языковая модель?	ChatGPT / DeepSeek / YandexGPT (или локальный аналог)	Модульный слой инференса (смена модели без переработки пайплайна); русскоязычный домен; on-prem, без внешних API; управляемые параметры генерации.	MVP: модель, доступная в периметре; Final: оптимизация качества/стоимости, бенчмарки.

Commented [AM02]: Сможем ли мы забирать информацию из Scorm форматов и Лонгридов из Академии Хайленд Голд (iSpring система) Можем ли мы добавить еще форматы фото/видео? Также если будем брать инфо из онлайн библиотеки МИФ нужно уточнить какой формат у них (TXT, FB2, Epub, RTF и тп)

7	Какие категории/темы?	Обратная связь, увольнение, адаптация, премирование, трудные разговоры, KPI, онбординг	Категории как метаданные для навигации, фильтрации и приоритизации; расширяемый классификатор без миграции схем.	MVP: базовый список; Final: доработка классификатора и синонимии.
8	Нужна ли цитируемость?	Желательна	Режим «с подтверждениями»: ссылки/цитаты с указанием источника, раздела, версии и даты; автоматическое включение для чувствительных тем; индикация неуверенности.	MVP: опционально, минимум — ссылки на источники; Final: полноформатные цитаты и подсветка фрагментов.
9	Требования по ИБ?	On-prem, без внешних API/облаков	Все компоненты в периметре; RBAC, аудит операций, шифрование транспорта; согласование архитектуры и модели с ИБ до пилота.	MVP: базовая модель ИБ и аудит; Final: полный комплект политик, отчётность, тесты на соответствие.

Commented [AM03]: Добавить темы: Постановка целей и ИПР Онбординг и пребординг

4. Основной функционал чат-бота

4.1. NLP-обработка

Бот принимает русскоязычные запросы в свободной форме, распознаёт синонимы и разные формулировки, корректно трактует HR-термины по контексту. На выходе формируется структурированное представление запроса (интент, ключевые параметры), пригодное для поиска. При недостатке данных бот задаёт 1–3 уточняющих вопроса. Диалоговый контекст хранится в пределах сессии.

4.2. Поиск по базе знаний (векторный)

Документы нормализуются, разбиваются на фрагменты, векторизуются и индексируются. Поиск выполняется семантическим сопоставлением запроса и фрагментов с ранжированием по близости и актуальности версии. Поддерживаются

фильтры по категории, типу менеджера, источнику и дате действия. Результат — список фрагментов с метаданными для генерации ответа.

4.3. Генерация ответа (RAG)

Ответ формируется только из найденных фрагментов и их метаданных. По умолчанию — кратко и по делу; по запросу — развёрнуто (шаги, условия применимости). При низкой уверенности бот возвращает ссылку на документ и/или сообщает об отсутствии достаточных данных без домыслов.

4.4. Уточнение неконкретных запросов

Если запрос расплывчат, бот запрашивает недостающие параметры (например, статус сотрудника, стадия процесса) и повторяет поиск. Количество уточнений минимально, формулировки однозначны.

4.5. Формат выдачи

Ответ структурируется на блоки: «что сделать», «как сделать», «исключения/риски», «ссылки». Версия и дата действия документа указываются, если влияют на применимость.

4.6. Интерфейсы

В рамках этапа MVP пользовательский интерфейс чат-бота реализуется посредством встраивания в существующие каналы без разработки самостоятельного фронтенда. Административные операции осуществляются через **встроенную страницу портала**, предназначенную для загрузки материалов и управления их видимостью; данная страница не является отдельным интерфейсом и не предполагает разработки отдельного приложения.

5. Работа с документами

5.1. Поддерживаемые форматы

Система обязана корректно обрабатывать PDF, DOCX, XLSX, PPTX. Для скан-PDF применяется OCR; для XLSX извлекаются таблицы с сохранением заголовков и листов; для PPTX учитываются текст слайдов и спикерские заметки; для DOCX — заголовки, списки, таблицы и сноски.

5.2. Загрузка и администрирование

В рамках этапа MVP отдельный административный интерфейс не создаётся. Загрузка и администрирование контента выполняются через встроенную страницу существующего корпоративного портала с аутентификацией по SSO/AD/LDAP и применением ролевой модели доступа. Страница предназначена для ручных и срочных операций при том, что основной поток обновлений осуществляется автоматически в соответствии с п. 5.3. На странице обеспечиваются загрузка материалов методом drag-and-drop и через форму, присвоение обязательных метаданных (категория, дата действия, версия, источник) и явное указание типов менеджеров, для которых материал доступен. Отображаются базовые статусы обработки и результаты валидации; доступен журнал ошибок и ручной перезапуск обработки. Порядок и объём автоматических и ручных обновлений, а также состав

материалов, подлежащих индексации, согласовываются с Марией (см. п. 5.5).
Массовая векторизация всего корпуса материалов «Академии» по умолчанию не выполняется и допускается только в пределах согласованной подвыборки, релевантной менеджерам.

5.3. Индексация и обновление

При загрузке или изменении документов выполняются нормализация, чанкование, векторизация и инкрементальная переиндексация без простоя сервиса. Должна быть поддержана плановая синхронизация с Confluence, Академией и другими источниками. Индекс хранит метаданные для фильтрации и приоритизации актуальных версий.

5.4. Фильтрация и видимость

Документы и фрагменты фильтруются по типу менеджера и тематике, а также по версии и дате действия. Видимость определяется ролевой моделью и организационными атрибутами пользователя.

6. Информационная безопасность

6.1. Размещение и периметр

Все компоненты решения (диалоговый сервис, индексатор, векторное хранилище, LLM-инференс, админ-панель, очереди задач, мониторинг и логирование) размещаются внутри корпоративной инфраструктуры (on-premise).

6.2. Доступ и права

Реализуется разграничение прав доступа (RBAC) для ролей «Администратор знаний», «Контент-менеджер», «Аудитор», «Пользователь». Аутентификация выполняется через корпоративные механизмы (SSO/AD/LDAP), признак «руководитель» и тип менеджера подтверждаются по КИС/1С при старте каждой сессии.

6.3. Журналирование и контроль

Все административные и пользовательские операции журналируются с указанием пользователя, времени, операции и объекта доступа. Транспорт шифруется, доступ к админ-интерфейсам ограничен сетевыми политиками и 2FA.

6.4. Согласование

Архитектура решения, перечень интеграций и выбранная LLM согласуются с подразделением ИБ до запуска пилотной эксплуатации и при каждом существенном изменении компонентов.

7. Модель и архитектура

7.1. Архитектурный подход.

Используется RAG-архитектура (Retrieval-Augmented Generation): модуль

семантического извлечения (векторный поиск, re-rank) + модуль генерации ответа на основе найденных фрагментов и метаданных. Контекст генерации ограничивается верифицированными выдержками для снижения риска галлюцинаций.

7.2. Языковая модель.

LLM выбирается по согласованию с ИБ. Приоритетный вариант - DeepSeek либо локальный аналог, доступный в периметре. Требуется модульный слой инференса (абстракция над провайдерами), позволяющий заменять модель без переработки остальных подсистем. Параметры генерации (температура, длина, формат ответа) конфигурируемы.

7.3. Векторная база.

В качестве векторного хранилища допускаются FAISS, Weaviate или аналог с поддержкой фильтрации по метаданным и горизонтального масштабирования. Индекс строится инкрементально, поддерживается переиндексация без простоя и контроль версий.


7.4. Замена и обновление компонентов.

Компоненты (LLM, эмбединги, re-ranker, векторное хранилище) изолируются через сервисные интерфейсы. Обновления выполняются по процедурам blue-green/rolling с возможностью отката. Требуется сохранение совместимости схемы метаданных и форматов индекса.

8. Пользовательский сценарий (User Flow)

1. Менеджер открывает интерфейс (мобильное приложение / внутренний портал).
2. Вводит вопрос в свободной форме:
"Как провести увольнение в связи с несоответствием?"
3. Бот обрабатывает запрос, извлекает релевантные документы.
4. Генерирует краткий, точный ответ с возможной ссылкой на регламент.
5. При необходимости — уточняет контекст:
"Это штатный сотрудник или на испытательном сроке?"
6. Предоставляет финальный ответ и рекомендации.

Commented [AM04]: Вероятно, нужно будет добавить еще один вариант входа: через чат-бот «Капитан Хайленд» в телеграме, пока мы его используем. В перспективе мы откажемся от него и будем использовать чат-бот в моб приложении, но это долгосрочные планы (не раньше 2027 года).



6.1. Инициация сессии и запуск интерфейса.

Пользователь открывает чат-бот в одном из каналов (корпоративный портал, мобильное приложение, «Капитан Хайленд»). Система создаёт контекст сессии и готовит среду для обработки запроса.

6.2. Ввод запроса и лингвистическая обработка.

Пользователь вводит вопрос в свободной форме. Система выполняет NLP-разбор: определяет интент, извлекает сущности (например, статус сотрудника, тип договора, период, подразделение), нормализует термины HR-домена и формирует структурированное представление запроса для поискового контура.

6.3. Семантический поиск и отсутствие данных.

На основании структурированного запроса выполняется векторный семантический поиск с применением фильтров и метаданных (категория, тип менеджера, версия, дата действия). Результаты ранжируются по релевантности и актуальности. При отсутствии релевантных фрагментов пользователю выводится уведомление о том, что данные не найдены, и предлагаются альтернативы: переход к соответствующему разделу базы знаний и/или контакты ответственных. Данная ветка является терминальной; для повторной попытки пользователь вводит новый запрос.

6.4. Уточнение параметров запроса.

Если найденные материалы указывают на неоднозначность, система инициирует краткий цикл уточнений (1–3 целевых вопроса), например о статусе сотрудника или стадии процесса. После получения ответа выполняется повторное извлечение и повторная оценка необходимости уточнений. Цикл завершается при достижении достаточной определённости параметров, после чего управление передаётся генеративному контуру.

6.5. Формирование ответа (RAG-подход).

Ответ формируется на основе подтверждённых фрагментов и их метаданных. В генеративную модель подаются только верифицированные выдержки; произвольные допущения исключаются. При низком уровне уверенности система переключается в экстрактивный режим или запрашивает дополнительное уточнение до формирования итоговой рекомендации.

6.6. Контроль актуальности версий.

Перед представлением ответа выполняется проверка наличия более новой версии документа. При обнаружении актуальной редакции пользователю выводится соответствующее уведомление с предложением перейти к обновлённому документу; после уведомления сценарий переходит к режиму подтверждений (см. п. 6.7).

6.7. Режим подтверждений (цитаты/ссылки).

По запросу пользователя, а также для чувствительных тем, система добавляет в ответ точные цитаты и гиперссылки на источники с указанием документа, раздела/пункта, версии и даты действия. Для длинных материалов предлагается переход на портал для развёрнутого просмотра. Если подтверждения не требуются, сценарий минует добавление цитат и сразу переходит к выводу итоговой выдачи.

6.8. Финальный формат выдачи.

Результат отображается структурировано: «Что сделать» (пошаговый перечень действий), «Как сделать» (краткие инструкции и условия применимости), «Исключения/риски» (если применимо), «Ссылки и версии» (документ, точный раздел/пункт, версия, дата действия). В мессенджере длинные ответы автоматически разбиваются на части; для полного просмотра доступна ссылка на портал.

6.9. Завершение сессии.

После отображения результата сессия может быть завершена либо продолжена новым запросом в текущем контексте. Смена темы фиксирует новый контекст при сохранении истории диалога; возврат к предыдущему контексту возможен по команде пользователя.

7. Этапы реализации

Этап	Содержание	Сроки
Подготовка	Согласование требований, сбор базы знаний, выбор модели	1 неделя
MVP	Интерфейс чат-бота, RAG-логика, интеграция 50 документов	3 недели
Пилот	Тестирование на пилотной группе менеджеров, сбор фидбека	1 неделя
Расширение	Добавление документов, разделение категорий, масштабирование	3 недели
Обучение	Документация и запуск	1 неделя

Commented [AM05]: На сбор базы знаний уйдет больше времени. Текущая информация, представленная на ресурсах доступна и ее можно взять за начало, но часть информации мне нужно будет собирать от коллег, начать уже сейчас не получится, тк не понятно будет ли из Confluence и академии тянутся инфо в тех форматах которые я описала выше и с учетом разграничения прав доступов

Commented [AM06]: По факту уйдет не меньше 2 недель с учетом коммуникации с активами

Этап	Результат (требования и критерии приёмки)	Срок
------	---	------

Подготовка	Согласованное ТЗ (use-cases, роли, ограничения), архитектурная схема, план качества и метрик; инвентаризация источников и формат индексации; выбор LLM/эмбедингов/векторного хранилища с обоснованием; план безопасности и доступов. Критерии: документы утверждены, метрики зафиксированы.	1 нед
MVP	Развёрнут стенд с чат-интерфейсом; реализован RAG-контур (ингест, индексация, поиск, цитирование); проиндексировано 50 документов ; включено логирование/телеметрия. Критерии: golden-set ≥100 вопросов; точность ≥80% по приоритетным сценариям; p95 задержки ответа ≤7 с; 100% ответов содержат ссылки на источники.	3 нед
Пилот	Запуск на пилотной группе; сбор телеметрии и пользовательского фидбэка; корректировки промтов и багфиксы по P0/P1. Критерии: прирост точности к MVP ≥10 п.п.; закрыты все P0/P1; стабильность стенда ≥99.5% аптайм.	1 нед
Расширение	Расширение корпуса (категории/ACL), оптимизация поиска (re-ranking/фильтры), мониторинг качества и свежести. Критерии: покрытие ≥1 000 документов; SLA индексации изменений ≤12 часов; p95 задержки ≤5 с; дашборды и алерты функционируют.	3 нед
Обучение и запуск	Подготовлены руководство пользователя, FAQ и короткий видео-гайд; Runbook поддержки и эскалаций; релиз в прод. Критерии: обучено ≥90% целевой аудитории (подтверждено регистрацией/просмотром гида); успешный smoke-тест в проде; канал поддержки доступен.	1 нед

8. Дополнительно

- В будущем возможно расширение в веб-формат или интеграцию с HRM-системой.
- Рекомендуется проработать систему **аналитики** (например, какие запросы задаются чаще).
- Возможна интеграция модуля обучения бота на пользовательских вопросах (через обратную связь).

Commented [AM07]: Возможно ли будет сделать аналитику в формате дашборда и выводить на Power BI или другой ресурс