

1. Оптимизация алгоритма построения графа знаний для более эффективных RAG-пайплайнов

Для получения точных и содержательных ответов в системах на основе Retrieval-Augmented Generation важно подготовить качественную базу знаний. Стандартный подход к поиску релевантной информации для ответа на пользовательский вопрос не всегда эффективен. Например, при ответе на абстрактные вопросы (вопросы, для ответа на которые необходимо найти и связать информацию из различных источников) информация разделена по всему корпусу текстов, из-за чего при использовании стандартного RAG может быть найдена лишь частично.

Один из способов подготовки текста для повышения качества поиска релевантной информации – [построение графа знаний](#). Выделение связей между сущностями и поиск смысловых сообществ в графе позволяют более эффективно структурировать информацию, тем самым повышая точность и полноту ответа.

Существующие решения для построения графа знаний и поиска информации по нему ([GraphRAG](#), [LightRAG](#)) имеют ряд недостатков: в частности, они используют большие языковые модели для построения графа знаний, что требует большого количества ресурсов и времени. Цель проекта – оптимизировать алгоритм для построения графа знаний за счет использования небольших специализированных моделей, адаптированных под русский язык, что позволит снизить вычислительные затраты на построение графа знаний и повысит релевантность ответов.

2. Доменно-специфичное распознавание речи с помощью audio-LLM

Ошибки распознавания речи обычно возникают, когда модель выбирает неверный вариант среди нескольких похоже звучащих слов. Здесь может помочь дополнительный контекст: указание тематики разговора, база текстов или слов по указанной тематике, предыдущая речь. Например, эти данные могут использоваться в контексте аудио-языковой LLM. Для оценки качества нужно подготовить данные, где каждый пример содержит длинное аудио, границы фрагмента, ручную транскрипцию для фрагмента и дополнительную базу, найденную в интернете по ключевым словам из автоматической транскрипции всего аудио или его фрагментов, имитируя создание базы во время инференса. Надо будет измерить качество транскрибации фрагмента аудио-LLM, подавая на вход фрагмент аудио, либо все аудио, с дополнительной базой текстов/слов или без нее. Это поможет улучшить качество русскоязычных систем распознавания речи, с перспективой научной публикации.

3. Проблема сдвига данных и робастное обучение БЯМ

Качество работы больших языковых моделей может определяться тем, насколько распределение данных, использовавшихся для обучения модели, отличается от распределения данных тестовой выборки, т.е. насколько велик т.н. “сдвиг” данных. Для преодоления этой проблемы исследователи разрабатывают различные методы робастного обучения, основной целью которого является формирование устойчивых к сдвигу данных (инвариантных) представлений. Такое обучение может включать в себя как изменение самой архитектуры модели, так и подбор большого количества наиболее разнообразных корпусов в обучающей выборке. В данном проекте мы рассмотрим различные техники робастного обучения (например, BIRM) и научимся применять их на практике.

4. АнтиКоллизия: поиск противоречий в тексте с помощью LLM

Современные LLM-сервисы умеют находить логические и фактические ошибки в текстах, однако полноразмерные решения (уровня ChatGPT) тяжеловесны, дороги и непригодны для конфиденциальных документов. Проект АнтиКоллизия исследует, как компактная открытая модель без дообучения, но с подключенным инструментом выборки знаний, способна выявлять внутренние противоречия в длинном документе — дублирующиеся, но расходящиеся определения, взаимоисключающие требования, битые перекрёстные ссылки, несогласованные числовые параметры и т.д., сверять утверждения текста с внешней компактной базой фактов и помечать расхождения.

5. RAG на табличных данных

RAG-пайплайны сталкиваются с особыми трудностями при работе с большими табличными данными. Стандартные методы извлечения информации, основанные на семантическом поиске по встраиваниям целых таблиц или крупных фрагментов, становятся вычислительно неэффективными и теряют точность из-за шума и размера данных. Цель проекта — исследовать и разработать стратегии эффективного поиска релевантного контекста для RAG в таких условиях. Участникам предстоит изучить подходы, включающие использование метаинформации (схемы БД) табличных данных и рассмотреть применение малых Text-to-SQL моделей, как высокоточных ‘ретриверов’ для формировании итогового ответа на запрос пользователя, или же для формирования компактных, релевантных выборок (контекстных ‘срезов’) перед их подачей в контекст языковой модели. Второй подход будет включать в себя аналогичное применение LLM для генерации pandas / sql кода. Фокус будет сделан на исследование баланса между точностью извлечения контекста и

вычислительной эффективностью при работе с объемными таблицами. Также, студенты упакуят свои решения в демонстрационные приложения.

6. Эффективная кросс-модальная RAG-система для унификации мультимодальных данных

Современные Retrieval-Augmented Generation (RAG) решения гармонично совмещают мощь крупных языковых моделей и векторных индексов для повышения достоверности ответов, однако традиционно ограничиваются только текстом и изображениями. Растущие потребности требуют кросс-модальных систем, способных учитывать и аудио, и видео, что особенно важно при анализе цифровых данных — ресурсов, совмещающих текст, видео-лекции, аудиокomentarии и интерактивные элементы.

В рамках проекта предлагается использовать унифицированные эмбединги с помощью Qwen2.5-Omni Thinker, дообученного по методике GME (instruction-based embedding + InfoNCE), создавая единое пространство для всех типов данных и обеспечивая Any-to-Any Retrieval без потери качества на сложных комбинированных запросах.

7. Мультиагентная система рецензирования с малыми языковыми моделями

В современной практике все большее применение БЯМ начинает опираться на использование сторонних интеграций и инструментов, а не на решение задач вслепую, исключительно силами самой БЯМ. Это позволяет уменьшить потребляемые БЯМ ресурсы, а также получать достоверные ответы, не заставляя БЯМ выполнять опции компилятора или калькулятора, а лишь руководить процессом. Такой сценарий использования снижает требования и к самой БЯМ, благодаря чему можно использовать модели меньшего размера, что также крайне актуально в практических задачах, уменьшая задержки для пользователя и снижая затраты компании. В рамках проекта предлагается разработать мультиагентную систему автоматического рецензирования научных статей, заменив ресурсоёмкие БЯМ ансамблем малых моделей с использованием современных фреймворков.

8. Дистилляция ризонинга в малые языковые модели

Идея поэтапного решения задачи в ходе “цепочки рассуждений” доказала свою эффективность во многих областях при решении наиболее сложных задач. Рассуждающая модель имеет широкое пространство поиска ответа и в сравнении с не-рассуждающими большими языковыми моделями в меньшей степени опирается на объем своих знаний – она не обязана выдавать ответ сразу, а может получить его опираясь на базовые знания и логику. Хорошим

примером здесь служит сравнение семейств моделей Qwen 3 и 2.5, где рассуждающая 4B модель смогла превзойти в логических задачах 72B модель не использующую данный подход.

Наибольшей проблемой для обучения моделей рассуждений является составление качественного и объемного набора данных, реалистичных и эффективных цепочек вывода. Но имея уже обученную полноразмерную модель, для малой модели это проблема легко решается с помощью различных методов дистилляции, нужные зависимости модель перенимает от учителя, а не изучает их напрямую из данных. Дистилляция позволяет создавать компактные модели, не требуя специализированных данных, а процесс обучения занимает значительно меньше времени.

В рамках данного проекта мы будем исследовать методы дистилляции способности к сложным рассуждениям (ризонингу) из больших языковых моделей в малые. Предлагается сгенерировать рассуждения LLM при решении задач QA (с помощью API), затем полученные рассуждения использовать как данные для обучения seq2seq малой языковой модели. Далее есть возможность погрузиться в RAG для расширения возможностей полученной малой рассуждающей модели. В результате мы ожидаем получить рабочий пайплайн для дистилляции ризонинга в малые модели и полученную с его помощью модель, протестированную на QA-датасетах.

9. Высокоуровневое управление роботом с помощью визуальных больших языковых моделей

Современные большие языковые модели достигли огромного успеха генерации текстов в совершенно различных задачах. Например, сейчас они используются для декомпозиции задач, имитации стилей или форматов текста, могут следовать инструкциям и планам. Более того, все больше языковых моделей становятся мультимодальными со способностью одновременно анализировать изображение и текстовую инструкцию, что открывает новые возможности для их использования. Например, для задач управления роботами, заменяя сложные, детерминированные алгоритмы на гибкое принятие решений на основе естественного языка. В данном проекте будет разработан и протестирован пайплайн, в котором VLM (например, Qwen, LLaVA) выступает в роли “мозга” для виртуального робота: на основе визуальных данных из симулятора и текстовой задачи пользователя модель генерирует последовательность команд для управления. Основной фокус работы будет направлен на исследование способностей существующих моделей, а также их доработку и создание собственных, сравнительный анализ их результативности и производительности в навигационных задачах.